

Applied Computer Vision 2026 - CheckPoint 5

Detecção de Ações de Pessoas com YOLO + U-Net + SlowFast

Prof. Dr. Paulo Sergio Rodrigues - Outubro de 2026

Açussena Macedo Mautone - RM 552568

Felipe Heilmann Marques - RM 551026

Felipe Voidela Toledo - RM 98595

Carlos Eduardo Caramante Ribeiro - RM 552159

Ian Cancian Nachtergaele - RM 98387

1. Pipeline

Todos os modelos são pré-treinados, sem treino adicional. **YOLO11n** (COCO, classe *person*) detecta cada pessoa e o rastreador **ByteTrack** mantém um ID por pessoa. Para cada caixa, a **U-Net** (U²-Net *human_seg*, uma U-Net aninhada treinada para segmentar pessoas, escolhida por manter a arquitetura codificador-decodificador com *skip connections* da U-Net e ter pesos públicos para pessoas) recebe um **recorte quadrado** centrado na caixa (margem de 25%), redimensionado para 320×320. O mapa de probabilidade é limiarizado em 0,5 e **projetado de volta** nas coordenadas do quadro original, limitado à caixa. O **SlowFast R50 8×8** (Kinetics-400, 400 ações) classifica janelas de 32 quadros com passo 16 (via rápida com 32 quadros e via lenta com 8). Cada janela é registrada com top-3 e confiança em *actions.csv* e roda duas vezes: no quadro inteiro e no recorte quadrado da união das caixas da janela (extensão opcional). No vídeo final, cada quadro mostra caixa, ID, confiança, máscara colorida com contorno e a ação da janela de centro mais próximo. Os três modelos também foram rodados isoladamente (*run_individual.py*) antes da integração. Tudo rodou em CPU: cerca de 1,6 s por quadro com 2 pessoas (a U-Net domina o custo) e cerca de 2 s por inferência do SlowFast.

2. Experimentos

V1: tiro com arco (10 s, 30 fps, 320×240, 2 arqueiras, câmera estável). **V2:** queda de braço (10 s, 28 fps, 340×256, close-up, câmera tremida, pessoas ao fundo). Também rodamos dois testes extras. O primeiro é um clipe de **transição**, com os últimos 4 s de V1 seguidos dos primeiros 4 s de V2 (corte no quadro 119, t = 3,97 s), para medir o que acontece quando a ação termina e outra começa. O segundo é um caso de falha, **pedestres** (OpenCV *vtest*, 10 fps, pessoas pequenas, ação *andar*, que não existe no Kinetics-400). Os momentos analisados são 20%, 50% e 80% de cada vídeo. **Modelos isolados** (passo 1, *outputs/*individual*): o YOLO sozinho encontra 2,00 e 3,12 pessoas/quadro em V1 e V2. A U-Net aplicada ao quadro inteiro, sem caixa, marca 18% e 36% dos pixels como pessoa, mas gera uma única máscara para todas as pessoas, por isso o recorte guiado pelo YOLO é necessário para ter uma máscara por pessoa. O SlowFast sozinho prevê *archery* e *arm wrestling*, as mesmas classes do pipeline integrado.

Vídeo	Quadros com pessoa	Pessoas/quadro	IDs únicos	Conf. YOLO	Preench. máscara*	Janelas	Acerto SlowFast (inteiro / recorte)	Conf. média top-1 (inteiro / recorte)
V1 arco	300/300	2,00	2	0,81	0,47	18	100% / 100%	1,00 / 1,00
V2 queda de braço	245/280	3,12	31	0,63	0,46	17	100% / 100%	1,00 / 1,00
Transição	231/231	2,75	14	0,70	0,45	14	100% / 100%	1,00 / 0,99
Pedestres	150/150	5,39	14	0,75	0,50	9	n/a / n/a	0,29 / 0,40

Tabela 1 - Resumo por vídeo. *Preench. máscara = pixels da máscara ÷ área da caixa (uma pessoa em pé ocupa tipicamente 40-60% da caixa).

Vídeo	t (s)	Caixa segue?	Máscara segue?	Preen ch.	Ação inteiro (conf.)	Ação recorte (conf.)	Bate ?	Observação
V1 arco	2,0	Sim (2/2)	Sim	0,55	archery (1,00)	archery (1,00)	Sim	corpo e chapéu inteiros
V1 arco	5,0	Sim (2/2)	Sim	0,49	archery (1,00)	archery (1,00)	Sim	corpo inteiro, com pernas
V1 arco	8,0	Sim (2/2)	Quase	0,44	archery (1,00)	archery (1,00)	Sim	perde calça vermelha do ID 1
V2 queda de braço	2,0	Parcial	Não	0,25	arm wrestling (1,00)	arm wrestling (1,00)	Sim	garoto: só o braço; oponente vaza p/ mesa
V2 queda de braço	5,0	Parcial	Parcial	0,79	arm wrestling (1,00)	arm wrestling (1,00)	Sim	garoto inteiro; oponente não detectado
V2 queda de braço	8,0	Não	Não	0,62	arm wrestling (1,00)	arm wrestling (1,00)	Sim	borrão: 1 caixa p/ 2 pessoas
Transição	1,5	Sim (2/2)	Sim	0,49	archery (1,00)	archery (1,00)	Sim	trecho de arco
Transição	3,8	Sim (2/2)	Sim	0,44	archery (1,00)	archery (1,00)	Sim	4 quadros antes do corte
Transição	6,1	Parcial	Parcial	0,20	arm wrestling (1,00)	arm wrestling (1,00)	Sim	ID 2 herdado; IDs 7 e 16 sem máscara
Pedestres	3,0	Parcial	Sim	0,66	playing cricket (0,13)	playing cricket (0,32)	Não	2 pessoas numa caixa; 1 oculta
Pedestres	7,5	Parcial	Sim	0,52	jogging (0,52)	jogging (0,65)	Não	pessoa atrás da placa perdida
Pedestres	12,0	Parcial	Sim	0,50	playing cricket (0,19)	jogging (0,17)	Não	pessoa na borda não detectada

Tabela 2 - Três momentos por vídeo (20%, 50% e 80% da duração). Quadros em *outputs/<vídeo>/moments*.




Figura 1 - (a) V1 t=5 s: caixas e máscaras corretas; (b) V2 t=2 s: máscara do garoto só no braço e a do oponente de preto vaza para mesa e fundo; (c) transição t=6,1 s: ID 2 herdado da arqueira e IDs 7 e 16 sem máscara; (d) pedestres t=3 s: duas pessoas numa única caixa, 'playing cricket' 13%.




Figura 2 - Confiança top-1 por janela no clipe de transição (corte em $t = 3,97$ s).

3. Respostas às perguntas

A caixa acompanha a pessoa? Sim, em V1: 300/300 quadros com as 2 pessoas e só 2 IDs no vídeo inteiro. Em V2, só parcialmente: com close-up, câmera tremida e oclusões, o ByteTrack gerou **31 IDs** para poucas pessoas reais, e 35 quadros (12,5%) ficaram sem nenhuma detecção. Nos pedestres a caixa segue bem quem está visível, mas falha com oclusão (pessoa atrás da placa) e junta pessoas lado a lado.

A máscara acompanha o contorno? Sim, para pessoas de corpo inteiro e visíveis (V1, pedestres: preenchimento de 0,47 a 0,50, contorno seguindo braços, chapéu e pernas). Em V2 a máscara falha quando a pessoa aparece só em parte (braço, ombro) ou se confunde com o fundo escuro. Quando a pessoa está pequena e ocluída ao fundo, a máscara sai praticamente vazia (preenchimento ~0).

A ação prevista corresponde ao trecho? Sim em V1 (*archery*, 18/18 janelas) e em V2 (*arm wrestling*, 17/17), as duas classes que existem no Kinetics-400. Nos pedestres, não: *andar* não está entre as 400 classes, e o modelo oscila entre *playing cricket*, *throwing ball* e *jogging* com confiança de 0,13 a 0,65.

A confiança cai ou a classe muda quando a ação começa ou termina? Sim. No clipe de transição, a janela 6 (quadros 96-127, só 9 do vídeo novo) continua *archery* 1,00, mas já com *arm wrestling* como 2ª classe. A janela 7 (quadros 112-143, que contém o corte) muda para *arm wrestling* com confiança de **0,94** (0,85 no recorte), e a janela 8 volta a 1,00. A troca de classe atrasa cerca de meia janela (~0,5 s). Fora das transições a confiança fica saturada em ~1,00, e a queda só aparece na janela que mistura as duas ações.

4. Erros explicados

E1 - Recorte esticado degradava a máscara (corrigido). Na 1ª versão, a caixa do YOLO (alta e estreita, ~80×200 px) era redimensionada direto para 320×320. A pessoa ficava ~2,5× mais larga e a U-Net, treinada com proporções naturais, segmentava só pedaços (calça, mochila). O preenchimento médio em V1 era de **0,26**. Trocando por um recorte **quadrado** com contexto (margem de 25%), o preenchimento subiu para **0,43** e a máscara passou a cobrir cabeça e tronco. Os testes automatizados acharam um 2º problema: quando o quadrado sai do vídeo (pessoa na borda), completar com a borda *replicada* cria listras que a U-Net confunde com fundo, e a máscara parava na cintura. Com borda *espelhada*, V1 foi para **0,47** e V2 de 0,38 para **0,46**. Ainda restam 19 de 600 máscaras de V1 com preenchimento < 0,3 (ex.: ID 2 nos primeiros quadros, só o tronco).

E2 - Troca e herança de ID no corte de cena. No quadro 119 da transição, o ByteTrack associou a caixa do garoto de V2 ao ID 2 da arqueira, porque as caixas se sobrepõem (IoU alto) e o rastreador só usa posição e movimento, não aparência. Em V2 o mesmo mecanismo, junto com câmera tremida e borrão, gera 31 IDs. Um rastreador com re-identificação por aparência (ex.: BoT-SORT com ReID) ou detectar cortes de cena e reiniciar o rastreador resolveria isso.

E3 - Ação sem pessoa e excesso de confiança do SlowFast. Em V2, nos quadros 187-208 o borrão deixa só antebraços visíveis e o YOLO não detecta ninguém. Nos quadros 252-267 o próprio arquivo tem blocos corrompidos de compressão. Mesmo assim o SlowFast responde *arm wrestling* com **1,00**: ele usa o contexto da janela inteira (32 quadros) e não verifica a pessoa. As saídas do modelo pré-treinado são extremamente confiantes (logit top-1 ~79 contra ~27 da 2ª classe), então 1,00 aqui não significa certeza calibrada.

E4 - Classe inexistente e pessoas pequenas (pedestres). Sem *walking* no Kinetics-400, o SlowFast é forçado a escolher a classe mais parecida e varia a cada janela. O vídeo em 10 fps também faz 32 quadros cobrirem 3,2 s em vez de ~1 s, um movimento diferente do que o modelo viu no treino. Além disso, com 5-6 pessoas espalhadas, a união das caixas cobre quase o quadro inteiro e o 'recorte da pessoa' quase não isola nada.

5. Extensão: SlowFast no quadro inteiro × no recorte da pessoa

Em V1, V2 e na transição, as duas entradas concordam em 100% das janelas, porque a ação ocupa quase todo o quadro e o contexto (alvos, mesa) é redundante. A diferença aparece na janela de transição (0,94 no quadro inteiro e 0,85 no recorte): o recorte tem menos contexto para desempatar. Nos pedestres o recorte **aumenta** a confiança média (0,29 → 0,40) e concorda com o quadro

inteiro em só 67% das janelas: remover a grama e o prédio reduz distrações, mas ainda não há classe correta. Conclusão: o recorte ajuda quando a pessoa é pequena no quadro e tende a prejudicar quando o contexto é parte da ação.

6. Parecer dos integrantes

Açussena Macedo Mautone (U-Net e projeção da máscara): O que mais me chamou atenção foi o peso do pré-processamento. Sem mexer no modelo, só trocar o recorte esticado por um quadrado levou o preenchimento de 0,26 para 0,43, e espelhar a borda levou para 0,47. A U²-Net ainda falha com pessoas pequenas ou cortadas pelo quadro (IDs 7 e 16 ficam sem máscara), o que faz sentido para um modelo treinado com pessoas inteiras e em primeiro plano.

Felipe Heilmann Marques (YOLO e leitura do vídeo): No vídeo do arco o YOLO foi impecável: 300/300 quadros e só 2 IDs. Na queda de braço ficou claro que o problema não é detectar, e sim rastrear. O ByteTrack olha só posição e movimento, por isso gerou 31 IDs e herdou o ID da arqueira no corte de cena. Como próximo passo, eu testaria um rastreador com re-identificação por aparência e um YOLO maior, para pegar o oponente de camisa preta.

Felipe Voidela Toledo (integração do pipeline e visualização): A parte mais difícil foi juntar escalas de tempo diferentes: YOLO e U-Net respondem por quadro, o SlowFast responde por janela de 32 quadros. Resolvemos mostrando em cada quadro a janela de centro mais próximo, e isso explica o atraso de ~0,5 s na troca de ação. O custo também pesa: na CPU são ~1,6 s por quadro, quase tudo na U-Net. Sem GPU, não dá para usar em tempo real.

Carlos Eduardo Caramante Ribeiro (SlowFast e classificação de ações): O SlowFast acertou todas as janelas de arco e de queda de braço. Mas a confiança de 1,00 em quadros borrados e até corrompidos mostra que esse número não é uma probabilidade em que dá para confiar. Nos pedestres ele ficou perdido porque 'andar' não existe no Kinetics-400. Aprendi que a lista de classes do pré-treino importa tanto quanto a arquitetura.

Ian Cancian Nachtergaele (experimentos, testes e apresentação): O clipe de transição foi a forma mais direta de responder se a classe muda quando a ação termina: a troca acontece, com queda de confiança para 0,94 só na janela que mistura as duas cenas. Os testes automatizados se pagaram: foi um deles que revelou a máscara cortada na cintura pela borda replicada. Sem eles, esse erro teria passado despercebido.