

# Applied Computer Vision 2026 - CheckPoint 5

## Detecção de Ações de Pessoas com YOLO + U-Net + SlowFast

Açússena Macedo Mautone - RM 552568  
Felipe Heilmann Marques - RM 551026  
Felipe Voidela Toledo - RM 98595  
Carlos Eduardo Caramante Ribeiro - RM 552159  
Ian Cancian Nachtergaele - RM 98387

### 1. Pipeline

Todos os modelos são pré-treinados, sem treino adicional. **YOLO11n** (COCO, classe *person*) detecta cada pessoa e o rastreador **ByteTrack** mantém um ID por pessoa. Para cada caixa, a **U-Net** (U<sup>2</sup>-Net *human\_seg*, uma U-Net aninhada treinada para segmentar pessoas) recebe um **recorte quadrado** centrado na caixa (margem de 25%), redimensionado para 320×320. O mapa de probabilidade é limiarizado em 0,5 e **projetado de volta** nas coordenadas do quadro original, limitado à caixa. O **SlowFast R50 8×8** (Kinetics-400, 400 ações) classifica janelas de 32 quadros com passo 16 (via rápida com 32 quadros e via lenta com 8). Cada janela é registrada com top-3 e confiança em *actions.csv* e roda duas vezes: no quadro inteiro e no recorte quadrado da união das caixas da janela (extensão opcional). No vídeo final, cada quadro mostra caixa, ID, confiança, máscara colorida com contorno e a ação da janela de centro mais próximo. Os três modelos também foram rodados isoladamente (*run\_individual.py*) antes da integração. Tudo rodou em CPU: cerca de 1,6 s por quadro com 2 pessoas (a U-Net domina o custo) e cerca de 2 s por inferência do SlowFast.

### 2. Experimentos

**V1:** tiro com arco (10 s, 30 fps, 320×240, 2 arqueiras, câmera estável). **V2:** queda de braço (10 s, 28 fps, 340×256, close-up, câmera tremida, pessoas ao fundo). Também rodamos dois testes extras. O primeiro é um clipe de **transição**, com os últimos 4 s de V1 seguidos dos primeiros 4 s de V2 (corte no quadro 119, t = 3,97 s), para medir o que acontece quando a ação termina e outra começa. O segundo é um caso de falha, **pedestres** (OpenCV *vtest*, 10 fps, pessoas pequenas, ação *andar*, que não existe no Kinetics-400). Os momentos analisados são 20%, 50% e 80% de cada vídeo.

| Vídeo             | Quadros com pessoa | Pessoas/quadro | IDs únicos | Conf. YOLO | Preench. máscara* | Janelas | Acerto SlowFast (inteiro / recorte) | Conf. média top-1 (inteiro / recorte) |
|-------------------|--------------------|----------------|------------|------------|-------------------|---------|-------------------------------------|---------------------------------------|
| V1 arco           | 300/300            | 2.0            | 2          | 0.81       | 0.47              | 18      | 100% / 100%                         | 1.00 / 1.00                           |
| V2 queda de braço | 245/280            | 3.12           | 31         | 0.63       | 0.46              | 17      | 100% / 100%                         | 1.00 / 1.00                           |
| Transição         | 231/231            | 2.75           | 14         | 0.70       | 0.45              | 14      | 100% / 100%                         | 1.00 / 0.99                           |
| Pedestres         | 150/150            | 5.39           | 14         | 0.75       | 0.50              | 9       | n/a / n/a                           | 0.29 / 0.40                           |

Tabela 1 - Resumo por vídeo. \*Preench. máscara = pixels da máscara ÷ área da caixa (uma pessoa em pé ocupa tipicamente 40-60% da caixa).

| Vídeo             | t (s) | Caixa segue? | Máscara segue? | Preench. | Ação inteiro (conf.)   | Ação recorte (conf.)   | Bate ? | Observação                                |
|-------------------|-------|--------------|----------------|----------|------------------------|------------------------|--------|-------------------------------------------|
| V1 arco           | 2.0   | Sim (2/2)    | Sim            | 0.55     | archery (1.00)         | archery (1.00)         | Sim    | corpo e chapéu inteiros                   |
| V1 arco           | 5.0   | Sim (2/2)    | Sim            | 0.49     | archery (1.00)         | archery (1.00)         | Sim    | corpo inteiro, com pernas                 |
| V1 arco           | 8.0   | Sim (2/2)    | Quase          | 0.44     | archery (1.00)         | archery (1.00)         | Sim    | perde calça vermelha do ID 1              |
| V2 queda de braço | 2.0   | Parcial      | Não            | 0.25     | arm wrestling (1.00)   | arm wrestling (1.00)   | Sim    | garoto: só o braço; oponente vaza p/ mesa |
| V2 queda de braço | 5.0   | Parcial      | Parcial        | 0.79     | arm wrestling (1.00)   | arm wrestling (1.00)   | Sim    | garoto inteiro; oponente não detectado    |
| V2 queda de braço | 8.0   | Não          | Não            | 0.62     | arm wrestling (1.00)   | arm wrestling (1.00)   | Sim    | borrão: 1 caixa p/ 2 pessoas              |
| Transição         | 1.5   | Sim (2/2)    | Sim            | 0.49     | archery (1.00)         | archery (1.00)         | Sim    | trecho de arco                            |
| Transição         | 3.8   | Sim (2/2)    | Sim            | 0.44     | archery (1.00)         | archery (1.00)         | Sim    | 4 quadros antes do corte                  |
| Transição         | 6.1   | Parcial      | Parcial        | 0.20     | arm wrestling (1.00)   | arm wrestling (1.00)   | Sim    | ID 2 herdado; IDs 7 e 16 sem máscara      |
| Pedestres         | 3.0   | Parcial      | Sim            | 0.66     | playing cricket (0.13) | playing cricket (0.32) | Não    | 2 pessoas numa caixa; 1 oculta            |
| Pedestres         | 7.5   | Parcial      | Sim            | 0.52     | jogging (0.52)         | jogging (0.65)         | Não    | pessoa atrás da placa perdida             |
| Pedestres         | 12.0  | Parcial      | Sim            | 0.50     | playing cricket (0.19) | jogging (0.17)         | Não    | pessoa na borda não detectada             |

Tabela 2 - Três momentos por vídeo (20%, 50% e 80% da duração). Quadros em outputs/<vídeo>/moments.




Figura 1 - (a) V1 t=5 s: caixas e máscaras corretas; (b) V2 t=2 s: máscara do garoto só no braço e a do oponente de preto vaza para mesa e fundo; (c) transição t=6,1 s: ID 2 herdado da arqueira e ID 7 sem máscara; (d) pedestres t=3 s: duas pessoas numa única caixa, 'playing cricket' 13%.




Figura 2 - Confiança top-1 por janela no clipe de transição (corte em t = 3,97 s).

### 3. Respostas às perguntas

**A caixa acompanha a pessoa?** Sim, em V1: 300/300 quadros com as 2 pessoas e só 2 IDs no vídeo inteiro. Em V2, só parcialmente: com close-up, câmera tremida e oclusões, o ByteTrack gerou **31 IDs** para poucas pessoas reais, e 35 quadros (12,5%) ficaram sem nenhuma detecção. Nos pedestres a caixa segue bem quem está visível, mas falha com oclusão (pessoa atrás da placa) e junta pessoas lado a lado.

**A máscara acompanha o contorno?** Sim, para pessoas de corpo inteiro e visíveis (V1, pedestres: preenchimento de 0,47 a 0,50, contorno seguindo braços, chapéu e pernas). Em V2 a máscara falha quando a pessoa aparece só em parte (braço, ombro) ou se confunde com o fundo escuro. Quando a pessoa está pequena e ocluída ao fundo, a máscara sai praticamente vazia (preenchimento ~0).

**A ação prevista corresponde ao trecho?** Sim em V1 (*archery*, 18/18 janelas) e em V2 (*arm wrestling*, 17/17), as duas classes que existem no Kinetics-400. Nos pedestres, não: *andar* não está entre as 400 classes, e o modelo oscila entre *playing cricket*, *throwing ball* e *jogging* com confiança de 0,13 a 0,65.

**A confiança cai ou a classe muda quando a ação começa ou termina?** Sim. No clipe de transição, a janela 6 (quadros 96-127, só 9 do vídeo novo) continua *archery* 1,00, mas já com *arm wrestling* como 2ª classe. A janela 7 (quadros 112-143, que contém o corte) muda para *arm wrestling* com confiança de **0,94** (0,85 no recorte), e a janela 8 volta a 1,00. A troca de classe atrasa cerca de meia janela (~0,5 s). Fora das transições a confiança fica saturada em ~1,00, e a queda só aparece na janela que mistura as duas ações.

### 4. Erros explicados

**E1 - Recorte esticado degradava a máscara (corrigido).** Na 1ª versão, a caixa do YOLO (alta e estreita, ~80×200 px) era redimensionada direto para 320×320. A pessoa ficava ~2,5× mais larga e a U-Net, treinada com proporções naturais, segmentava só pedaços (calça, mochila). O preenchimento médio em V1 era de **0,26**. Trocando por um recorte **quadrado** com contexto (margem de 25%), o preenchimento subiu para **0,43** e a máscara passou a cobrir cabeça e tronco. Os testes automatizados acharam um 2º problema: quando o quadrado sai do vídeo (pessoa na borda), completar com a borda *replicada* cria listras que a U-Net confunde com fundo, e a máscara parava na cintura. Com borda *espelhada*, V1 foi para **0,47** e V2 de 0,38 para **0,46**. Ainda restam 19 de 600 máscaras de V1 com preenchimento < 0,3 (ex.: ID 2 nos primeiros quadros, só o tronco).

**E2 - Troca e herança de ID no corte de cena.** No quadro 119 da transição, o ByteTrack associou a caixa do garoto de V2 ao ID 2 da arqueira, porque as caixas se sobrepõem (IoU alto) e o rastreador só usa posição e movimento, não aparência. Em V2 o mesmo mecanismo, junto com câmera tremida e borrão, gera 31 IDs. Um rastreador com re-identificação por aparência (ex.: BoT-SORT com ReID) ou detectar cortes de cena e reiniciar o rastreador resolveria isso.

**E3 - Ação sem pessoa e excesso de confiança do SlowFast.** Em V2, nos quadros 187-208 o borrão deixa só antebraços visíveis e o YOLO não detecta ninguém. Nos quadros 252-267 o próprio arquivo tem blocos corrompidos de compressão. Mesmo assim o SlowFast responde *arm wrestling* com **1,00**: ele usa o contexto da janela inteira (32 quadros) e não verifica a pessoa. As saídas do modelo pré-treinado são extremamente confiantes (logit top-1 ~79 contra ~27 da 2ª classe), então 1,00 aqui não significa certeza calibrada.

**E4 - Classe inexistente e pessoas pequenas (pedestres).** Sem *walking* no Kinetics-400, o SlowFast é forçado a escolher a classe mais parecida e varia a cada janela. O vídeo em 10 fps também faz 32 quadros cobrirem 3,2 s em vez de ~1 s, um movimento diferente do que o modelo viu no treino. Além disso, com 5-6 pessoas espalhadas, a união das caixas cobre quase o quadro inteiro e o 'recorte da pessoa' quase não isola nada.

### 5. Extensão: SlowFast no quadro inteiro × no recorte da pessoa

Em V1, V2 e na transição, as duas entradas concordam em 100% das janelas, porque a ação ocupa quase todo o quadro e o contexto (alvos, mesa) é redundante. A diferença aparece na janela de transição (0,94 no quadro inteiro e 0,85 no recorte): o recorte tem menos contexto para desempatar. Nos pedestres o recorte  **aumenta**  a confiança média (0,29 → 0,40) e concorda com o quadro

inteiro em só 67% das janelas: remover a grama e o prédio reduz distrações, mas ainda não há classe correta. Conclusão: o recorte ajuda quando a pessoa é pequena no quadro e tende a prejudicar quando o contexto é parte da ação.

## 6. Parecer dos integrantes

**Açussena Macedo Mautone** (U-Net e projeção da máscara): O que mais me chamou atenção foi o peso do pré-processamento. Sem mexer no modelo, só trocar o recorte esticado por um quadrado levou o preenchimento de 0,26 para 0,43, e espelhar a borda levou para 0,47. A U<sup>2</sup>-Net ainda falha com pessoas pequenas ou cortadas pelo quadro (IDs 7 e 16 ficam sem máscara), o que faz sentido para um modelo treinado com pessoas inteiras e em primeiro plano.

**Felipe Heilmann Marques** (YOLO e leitura do vídeo): No vídeo do arco o YOLO foi impecável: 300/300 quadros e só 2 IDs. Na queda de braço ficou claro que o problema não é detectar, e sim rastrear. O ByteTrack olha só posição e movimento, por isso gerou 31 IDs e herdou o ID da arqueira no corte de cena. Como próximo passo, eu testaria um rastreador com re-identificação por aparência e um YOLO maior, para pegar o oponente de camisa preta.

**Felipe Voidela Toledo** (integração do pipeline e visualização): A parte mais difícil foi juntar escalas de tempo diferentes: YOLO e U-Net respondem por quadro, o SlowFast responde por janela de 32 quadros. Resolvemos mostrando em cada quadro a janela de centro mais próximo, e isso explica o atraso de ~0,5 s na troca de ação. O custo também pesa: na CPU são ~1,6 s por quadro, quase tudo na U-Net. Sem GPU, não dá para usar em tempo real.

**Carlos Eduardo Caramante Ribeiro** (SlowFast e classificação de ações): O SlowFast acertou todas as janelas de arco e de queda de braço. Mas a confiança de 1,00 em quadros borrados e até corrompidos mostra que esse número não é uma probabilidade em que dá para confiar. Nos pedestres ele ficou perdido porque 'andar' não existe no Kinetics-400. Aprendi que a lista de classes do pré-treino importa tanto quanto a arquitetura.

**Ian Cancian Nachtergaele** (experimentos, testes e apresentação): O clipe de transição foi a forma mais direta de responder se a classe muda quando a ação termina: a troca acontece, com queda de confiança para 0,94 só na janela que mistura as duas cenas. Os testes automatizados se pagaram: foi um deles que revelou a máscara cortada na cintura pela borda replicada. Sem eles, esse erro teria passado despercebido.